Descripción del proyecto

Te han ofrecido hacer prácticas en el departamento de analítica de Showz, una empresa d de entradas de eventos. Tu primera tarea es ayudar a optimizar los gastos de marketing.

```
In [1]: import pandas as pd
       import matplotlib.pyplot as plt
       import seaborn as sns
In [2]: # Cargar los datos
       df_visits = pd.read_csv('/datasets/visits_log_us.csv')
       df_orders = pd.read_csv('/datasets/orders_log_us.csv')
       df_costs = pd.read_csv('/datasets/costs_us.csv')
In [3]: # Mostrar las primeras filas de cada dataset
       print("\nVisits Data:")
       print(df_visits.head())
       Visits Data:
                                End Ts
                                       Source Id
           Device
                                                             Start Ts \
       0
           touch 2017-12-20 17:38:00
                                           4 2017-12-20 17:20:00
       1 desktop 2018-02-19 17:21:00
                                              2 2018-02-19 16:53:00
                                             5 2017-07-01 01:54:00
9 2018-05-20 10:59:00
          touch 2017-07-01 01:54:00
       2
       3 desktop 2018-05-20 11:23:00
       4 desktop 2017-12-27 14:06:00
                                             3 2017-12-27 14:06:00
                           Uid
       0 16879256277535980062
       1
          104060357244891740
       2
          7459035603376831527
       3 16174680259334210214
           9969694820036681168
In [4]: print("\nOrders Data:")
       print(df_orders.head())
       Orders Data:
                                                        Uid
                       Buy Ts Revenue
       0 2017-06-01 00:10:00
                                17.00
                                       10329302124590727494
       1 2017-06-01 00:25:00
                                 0.55
                                       11627257723692907447
                                 0.37
       2 2017-06-01 00:27:00
                                       17903680561304213844
       3 2017-06-01 00:29:00
                                 0.55 16109239769442553005
       4 2017-06-01 07:58:00
                                 0.37 14200605875248379450
In [5]: print("\nCosts Data:")
       print(df costs.head())
       Costs Data:
          source id
                            dt costs
       0
                 1 2017-06-01 75.20
                  1 2017-06-02 62.25
       1
       2
                 1 2017-06-03 36.53
       3
                 1 2017-06-04 55.00
                  1 2017-06-05 57.08
```

```
In [6]: # Verificar los datos
       print('Visits:')
       df visits.info()
       print()
       print('Orders:')
       df orders.info()
       print()
       print('Costs:')
       df costs.info()
       Visits:
       <class 'pandas.core.frame.DataFrame'>
       RangeIndex: 359400 entries, 0 to 359399
       Data columns (total 5 columns):
           Column
                     Non-Null Count
                                       Dtype
           -----
                      -----
       0 Device 359400 non-null object
1 End Ts 359400 non-null object
           Source Id 359400 non-null int64
        2
           Start Ts 359400 non-null object
        4
           Uid
                     359400 non-null uint64
       dtypes: int64(1), object(3), uint64(1)
       memory usage: 13.7+ MB
       Orders:
       <class 'pandas.core.frame.DataFrame'>
       RangeIndex: 50415 entries, 0 to 50414
       Data columns (total 3 columns):
       # Column Non-Null Count Dtvpe
                   -----
       ___
       0
           Buy Ts
                    50415 non-null object
           Revenue 50415 non-null float64
        2
           Uid
                    50415 non-null uint64
       dtypes: float64(1), object(1), uint64(1)
       memory usage: 1.2+ MB
       Costs:
       <class 'pandas.core.frame.DataFrame'>
       RangeIndex: 2542 entries, 0 to 2541
       Data columns (total 3 columns):
                      Non-Null Count Dtype
           Column
                      _____
        0
           source_id 2542 non-null int64
        1
                     2542 non-null object
                     2542 non-null float64
       dtypes: float64(1), int64(1), object(1)
       memory usage: 59.7+ KB
```

Optimizar los datos

```
In [7]: # Renombrar columnas
    df_visits.rename(columns={"Start Ts": "start_ts", "End Ts": "end_ts"}, inj
    df_orders.rename(columns={"Buy Ts": "buy_ts"}, inplace=True)

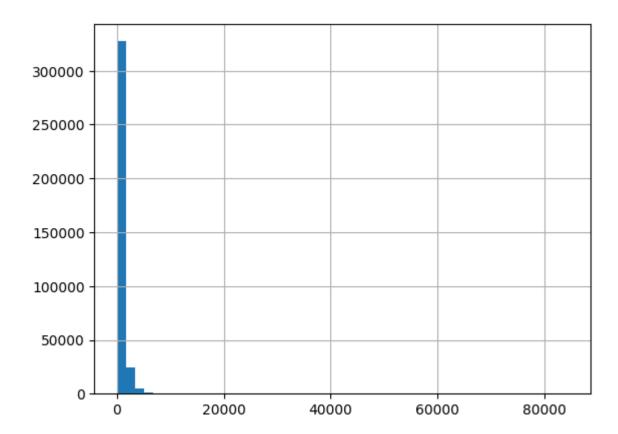
# Convertir columnas a datetime
    df_visits["start_ts"] = pd.to_datetime(df_visits["start_ts"])
    df_visits["end_ts"] = pd.to_datetime(df_visits["end_ts"])
    df_orders["buy_ts"] = pd.to_datetime(df_orders["buy_ts"])
    df_costs["dt"] = pd.to_datetime(df_costs["dt"])
```

Paso 2: informes y calcular métricas

Métricas de visitas

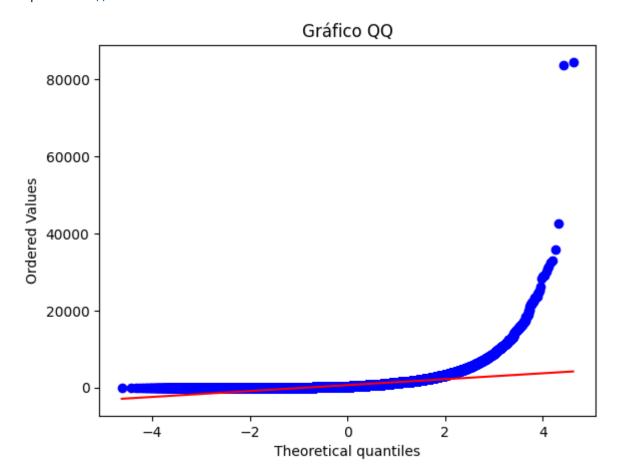
```
In [8]: # Crear nuevas columnas datetime
       df_visits['session_year'] = df_visits['start_ts'].dt.isocalendar().year
       df_visits['session_month'] = df_visits['start_ts'].dt.month
       df visits['session week'] = df visits['start ts'].dt.isocalendar().week
       df visits['session date'] = df visits['start ts'].dt.date
       print(df visits.head())
          Device
                             end ts Source Id
                                                         start ts \
          touch 2017-12-20 17:38:00 4 2017-12-20 17:20:00
                                         2 2018-02-19 16:53:00
5 2017-07-01 01:54:00
       1 desktop 2018-02-19 17:21:00
      2 touch 2017-07-01 01:54:00
      3 desktop 2018-05-20 11:23:00
                                           9 2018-05-20 10:59:00
      4 desktop 2017-12-27 14:06:00 3 2017-12-27 14:06:00
                          Uid session_year session_month session_week \
      0 16879256277535980062
                                      2017
                                                      12
                                                                    51
      1
          104060357244891740
                                      2018
                                                       2
                                                                    8
      2 7459035603376831527
                                                       7
                                                                    26
                                     2017
      3 16174680259334210214
                                                      5
                                     2018
                                                                   20
         9969694820036681168
                                      2017
                                                      12
                                                                    52
        session date
        2017-12-20
      1 2018-02-19
      2 2017-07-01
      3 2018-05-20
      4 2017-12-27
In [9]: # Usuarios por día y semana
       dau total = df visits.groupby('session date').agg({'Uid': 'nunique'}).mear
       wau_total = df_visits.groupby(['session_year', 'session_week']).agg({'Uid
       print(f'Usuarios por día = {int(dau total)}')
       print(f'Usuarios por semana = {int(wau total)}')
       Usuarios por día = 907
      Usuarios por semana = 5716
```

```
In [10]: # Sesiones de usuario
        df visits['end ts'] = pd.to datetime(df visits['end ts'])
        df visits['session year'] = df visits['start ts'].dt.year
        df_visits['session_month'] = df_visits['start_ts'].dt.month
        sessions_per_user = df_visits.groupby(['session_year', 'session_month']).
            {'Uid': ['count', 'nunique']}
        sessions per user.columns = ['n sessions', 'n users']
        sessions_per_user['sessions_per_user'] = (
            sessions per user['n sessions'] / sessions per user['n users']
        print(sessions per user)
                                   n_sessions n_users sessions_per_user
        session year session month
        2017
                    6
                                        16505
                                                13259
                                                                1.244815
                    7
                                       17828 14183
                                                               1.256998
                    8
                                       14355 11631
                                                               1.234202
                                       23907 18975
37903 29692
                    9
                                                               1.259921
                    10
                                                               1.276539
                    11
                                       43969 32797
                                                               1.340641
                    12
                                       41983 31557
                                                               1.330386
                                       36939 28716
        2018
                    1
                                                               1.286356
                                                               1.293332
                    2
                                       37182 28749
                                       35679 27473
                    3
                                                               1.298693
                                       26515 21008
                    4
                                                               1.262138
                                       26635 20701
                    5
                                                               1.286653
In [11]: # Duración media de la sesión o ASL
        df visits['session duration sec'] = (df visits['end ts'] - df visits['star
        print('La duración media por sesión es:')
        print(df_visits['session_duration_sec'].mean())
        La duración media por sesión es:
        643.506488592098
In [12]: # Veamos la distribución
        df_visits['session_duration_sec'].hist(bins=50)
        plt.show()
```



In [13]: import scipy.stats as stats

```
stats.probplot(df\_visits['session\_duration\_sec'], \ dist="norm", \ plot=plt) \\ plt.title("Gráfico \ QQ") \\ plt.show()
```

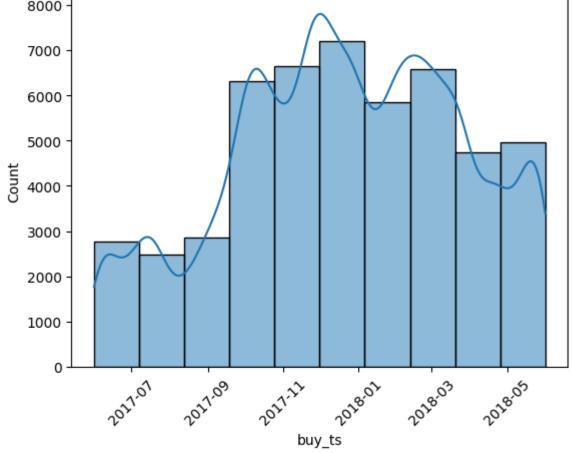


Conclusión

• Las sesiones tienen una distribución normal o casi normal.

Métricas de ventas

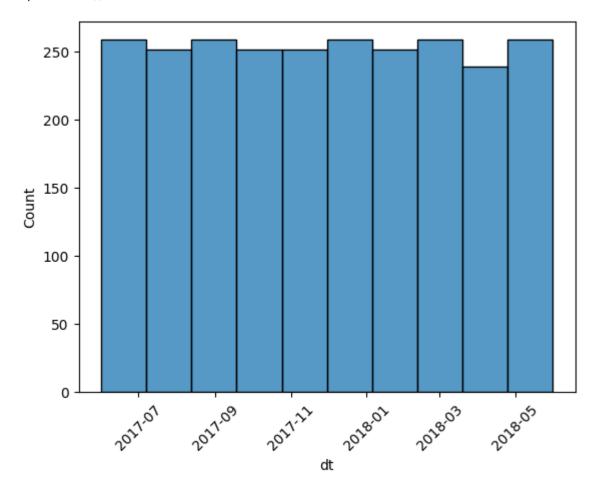
```
In [14]: df_orders['buy_ts'].describe()
Out[14]: count
                                  50415
                                  45991
         unique
                   2018-05-31 10:13:00
         top
         freq
         first
                   2017-06-01 00:10:00
                   2018-06-01 00:02:00
         last
         Name: buy_ts, dtype: object
In [15]: plt.xticks(rotation=45)
         sns.histplot(df_orders['buy_ts'].astype("datetime64"), bins=10, kde=True,
         plt.show()
           8000
           7000
```



```
In [16]: df_costs['dt'].describe()
```

```
Out[16]: count 2542
unique 364
top 2017-06-28 00:00:00
freq 7
first 2017-06-01 00:00:00
last 2018-05-31 00:00:00
Name: dt, dtype: object
```

• El rango de fechas de gastos coincide con el de fechas de pedidos.



```
In [18]: # Cohortes mensuales
         df_orders['order_month'] = df_orders['buy_ts'].astype('datetime64[M]')
         df costs['month'] = df costs['dt'].astype('datetime64[M]')
         # Recuperar el mes de la primera compra de cada cliente
         first_orders = df_orders.groupby('Uid').agg({'order_month': 'min'}).reset
         first orders.columns = ['uid', 'first order month']
         first orders.head()
         # Calcularemos el número de nuevos clientes (n buyers) para cada mes
         cohort sizes = first orders.groupby('first order month').agg({'uid': 'nun:
         cohort sizes.columns = ['first order month', 'n buyers']
         cohort sizes.head()
Out[18]:
            first_order_month n_buyers
         0
                  2017-06-01
                                2023
         1
                  2017-07-01
                                1923
         2
                  2017-08-01
                                1370
         3
                  2017-09-01
                                2581
         4
                  2017-10-01
                                4340
```

• Creemos cohortes, Vamos a agregar los meses de la primera compra de los clientes a la tal pedidos:

Out[20]:		buy_ts	Revenue	uid	order_month	first_order_month
	0	2017-06-01 00:10:00	17.00	10329302124590727494	2017-06-01	2017-06-01
	1	2017-06-01 00:25:00	0.55	11627257723692907447	2017-06-01	2017-06-01
	2	2017-06-01 00:27:00	0.37	17903680561304213844	2017-06-01	2017-06-01
	3	2017-06-01 00:29:00	0.55	16109239769442553005	2017-06-01	2017-06-01
	4	2017-06-01 07:58:00	0.37	14200605875248379450	2017-06-01	2017-06-01

```
cohorts = df orders .groupby(['first order month','order month']).agg({'Re
         cohorts.head()
Out[21]:
            first_order_month order_month Revenue
          0
                   2017-06-01
                                2017-06-01
                                            9557.49
          1
                   2017-06-01
                                2017-07-01
                                            981.82
          2
                   2017-06-01
                                2017-08-01
                                            885.34
          3
                   2017-06-01
                               2017-09-01
                                            1931.30
          4
                   2017-06-01
                               2017-10-01
                                            2068.58
In [22]: # Agregar datos sobre cuántos usuarios realizaron sus primeras compras en
         report = pd.merge(cohort_sizes, cohorts, on='first_order_month')
         report.head()
            first_order_month n_buyers order_month Revenue
Out[22]:
          0
                   2017-06-01
                                  2023
                                         2017-06-01
                                                     9557.49
          1
                   2017-06-01
                                  2023
                                         2017-07-01
                                                      981.82
          2
                   2017-06-01
                                  2023
                                         2017-08-01
                                                      885.34
                                                     1931.30
          3
                   2017-06-01
                                  2023
                                         2017-09-01
          4
                   2017-06-01
                                  2023
                                         2017-10-01
                                                     2068.58
In [23]: # Hagamos que las columnas muestren la edad de la cohorte en lugar del me:
         import numpy as np
         margin rate = 0.5
         report['gp'] = report['Revenue'] * margin_rate
         report['age'] = (
              report['order month'] - report['first order month']
         ) / np.timedelta64(1, 'M')
         report['age'] = report['age'].round().astype('int')
         report.head()
Out[23]:
            first_order_month n_buyers order_month Revenue
                                                                   gp age
          0
                   2017-06-01
                                  2023
                                         2017-06-01
                                                     9557.49 4778.745
                                                                         0
          1
                   2017-06-01
                                  2023
                                         2017-07-01
                                                      981.82
                                                              490.910
                                                                         1
          2
                   2017-06-01
                                  2023
                                         2017-08-01
                                                      885.34
                                                                         2
                                                              442.670
          3
                   2017-06-01
                                  2023
                                         2017-09-01
                                                     1931.30
                                                              965.650
                                                                         3
          4
                   2017-06-01
                                  2023
                                         2017-10-01
                                                     2068.58 1034.290
                                                                         4
```

In [21]: # Agrupar la tabla de pedidos por mes de la primera compra y mes de la compra y

```
In [24]: # Calcular el LTV
        report['ltv'] = report['gp'] / report['n buyers']
        output = report.pivot table(
           index='first order month',
           columns='age',
           values='ltv',
           aggfunc='mean').round()
        output.fillna('')
Out[24]:
                       0
                          1 2 3
                                    4
                                         5
                                             6
                                                7
                                                  8
                                                       9 10
                                                             11
                  age
        first_order_month
             2017-09-01 3.0 1.0 0.0 2.0 0.0 0.0 0.0 0.0 0.0
             2017-10-01 3.0 0.0 0.0 0.0 0.0 0.0 0.0 0.0
             2017-11-01 3.0 0.0 0.0 0.0 0.0 0.0 0.0
             2017-12-01 2.0 0.0 0.0 1.0 0.0 0.0
             2018-01-01 2.0 0.0 0.0 0.0 0.0
             2018-02-01 2.0 0.0 0.0 0.0
             2018-03-01 2.0 0.0 0.0
             2018-04-01 2.0 0.0
             2018-05-01 2.0
             2018-06-01 2.0
In [25]: # Encontremos el LTV de la primera cohorte sumando el valor de cada mes
        ltv_201803 = output.loc['2017-06-01'].sum()
        print(f'El LTV es: {ltv 201803}')
       El LTV es: 3.0
        Métricas de marketing
In [26]: # obtener la cohorte necesaria
        cohort_201803 = report[report['first_order_month'] == '2017-06-01']
        # calcular los costos para el mes de la cohorte
        costs_201803 = df_costs[df_costs['month'] == '2017-06-01']['costs'].sum()
        n_buyers_201803 = cohort_201803['n_buyers'][0]
        cac_201803 = costs_201803 / n_buyers_201803
        ltv 201803 = output.loc['2018-03-01'].sum()
        print('CAC =', cac_201803)
```

print('LTV =', ltv_201803)

```
CAC = 8.905091448344043
LTV = 2.0
```

Adquirir cada cliente le costó a la empresa un promedio de 8.91 mientras que cada cliente ç
 2.00. Por lo tanto, la inversión en la adquisición de clientes no obtuvo resultados positivos y
 hubo pérdida.

```
In [27]: # calcular los costos por mes
         monthly costs = df costs.groupby('month').sum()
         monthly_costs.head()
Out[27]:
                     source_id
                                  costs
             month
          2017-06-01
                         1020 18015.00
          2017-07-01
                         1054 18240.59
          2017-08-01
                         1054 14790.54
          2017-09-01
                         1020 24368.91
          2017-10-01
                         1054 36322.88
In [28]: # Agreguemos los datos sobre los costos al informe y calculemos el CAC
         report_ = pd.merge(report, monthly_costs, left_on='first_order_month', rig
         report ['cac'] = report ['costs'] / report ['n buyers']
         report .head()
Out[28]:
            first_order_month n_buyers order_month Revenue
                                                                   gp age
                                                                                 Itv source_
          0
                                                                         0 2.362207
                   2017-06-01
                                  2023
                                         2017-06-01
                                                     9557.49 4778.745
                                                                                          10
          1
                   2017-06-01
                                  2023
                                         2017-07-01
                                                      981.82
                                                               490.910
                                                                         1 0.242664
                                                                                          10
          2
                   2017-06-01
                                  2023
                                         2017-08-01
                                                      885.34
                                                               442.670
                                                                         2 0.218819
                                                                                          10
          3
                   2017-06-01
                                  2023
                                         2017-09-01
                                                     1931.30
                                                                         3 0.477336
                                                                                          10
                                                               965.650
          4
                   2017-06-01
                                  2023
                                         2017-10-01
                                                     2068.58 1034.290
                                                                         4 0.511265
                                                                                          10
```

ROMI

```
In [29]: report_['romi'] = report_['ltv'] / report_['cac']
    output = report_.pivot_table(
        index='first_order_month',
        columns='age',
        values='romi',
        aggfunc='mean')
    output.cumsum(axis=1).round(2)
```

2

1

0

age

3

5

6

10

9

8

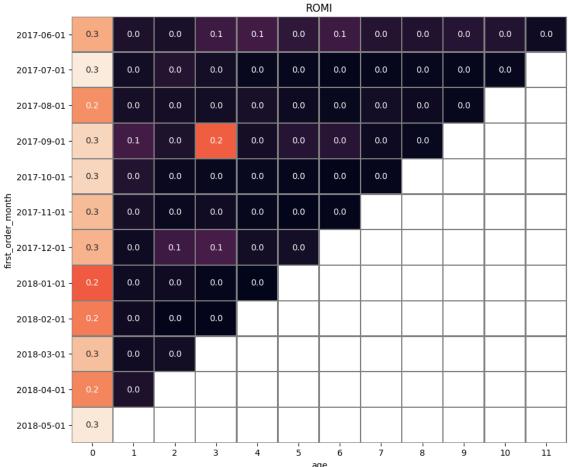
11

Visualización ROMI

Out[29]:

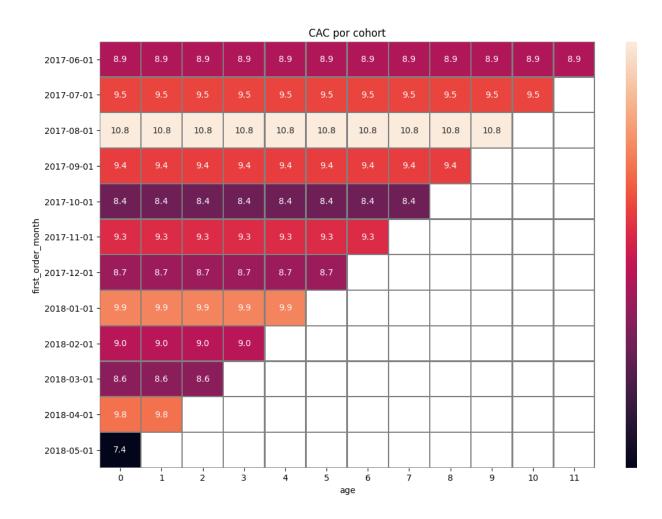
```
In [36]: report ['romi'] = report_['ltv'] / report_['cac']
         output = report_.pivot_table(
             index='first_order_month',
             columns='age',
             values='romi',
             aggfunc='mean')
         output.cumsum(axis=1).round(2)
         output.index = output.index.strftime('%Y-%m-%d')
         plt.figure(figsize=(13, 9))
         plt.title('ROMI')
         sns.heatmap(
             output,
             annot=True,
             fmt='.1f',
             linewidths=1,
             linecolor='grey',
         plt.show()
```





Visualización de datos - Gráficos

```
In [38]: # Creación de tablas dinamicas - Mapa de calor CAC
         cac_x_cohort = report_.pivot_table(
             index="first_order_month",
             columns="age",
             values="cac",
             aggfunc="mean"
         )
         cac_x_cohort.index = cac_x_cohort.index.strftime('%Y-%m-%d')
         plt.figure(figsize=(13, 9))
         plt.title('CAC por cohort')
         sns.heatmap(
             cac_x_cohort,
             annot=True,
             fmt='.1f',
             linewidths=1,
             linecolor='grey',
         plt.show()
```



Conclusión

• Lo que nos dice el informe es que ninguna cohorte tuvo un buen rendimiento en ningun mes fracaso total. Sin embargo se puede ver que a pesar de no ser rentable, cada cohorte mejor mes aumentando sus cifras.

Recomendación

- Buscar otra estrategia.
- Reducir el CAC aunque esto puede repercutir negativamente a la hora de llegar a otros clie
- Ya que vemos que los numeros aumentan mes a mes, no todo es malo, podriamos sacar al ahi para implementar una nueva estrategia.

Conclusiones y Recomendaciones

Tras analizar los datos de visitas, órdenes y costos del marketing para Showz, se pueden extrae siguientes conclusiones:

- Rendimiento general: Se observan variaciones significativas en el rendimiento entre difere días y semanas, lo que indica que el comportamiento del usuario cambia dependiendo de la temporada o campañas específicas.
- **Gasto publicitario**: Algunas campañas o días presentan un costo elevado sin un retorno proporcional en órdenes, lo que sugiere una posible ineficiencia.
- **Tendencias de conversión**: Existen días con una mejor tasa de conversión, lo cual puede aprovecharse optimizando el calendario de campañas.

Recomendaciones para el equipo de marketing:

- 1. **Revisar los días de bajo rendimiento**: Identificar qué factores externos pueden estar afection conversión esos días (tipo de evento, día de la semana, etc.).
- 2. **Optimizar el presupuesto**: Redistribuir la inversión hacia los días y canales que generan u relación costo/beneficio.
- 3. **Realizar pruebas A/B**: Evaluar cambios en los anuncios o en la segmentación del público paumentar la efectividad de las campañas.
- 4. **Monitoreo continuo**: Establecer un sistema de monitoreo semanal para reaccionar rápidan ante campañas poco efectivas.

Este análisis ofrece un punto de partida para una estrategia de marketing basada en datos, lo cu permite tomar decisiones más acertadas y eficientes.